

MIMIC-IV 기반 ICU 섬망 예측 모델 연구 보고서

프로젝트: YonseiAI Challenge - Delirium Prediction 데이터셋: MIMIC-IV (Medical Information Mart for Intensive Care) 작성일: 2026-02-05

목차

- [연구 개요](#)
- [데이터 추출](#)
- [데이터 전처리](#)
- [탐색적 데이터 분석](#)
- [모델링](#)
- [결과](#)
- [결론 및 논의](#)

1. 연구 개요

1.1 연구 목적

중환자실(ICU) 환자에서 섬망(Delirium)은 사망률 증가, 재원 기간 연장, 인지 기능 저하와 연관된 중요한 임상 문제입니다. 본 연구는 MIMIC-IV 데이터베이스를 활용하여 **CAM-ICU (Confusion Assessment Method for ICU) 평가 시점을 기준으로 섬망 발생을 예측**하는 머신러닝 모델을 개발하고 평가하는 것을 목적으로 합니다.

1.2 연구 설계

- 예측 타겟:** CAM-ICU 양성 여부 (0: 음성, 1: 양성)
- 예측 윈도우:** CAM-ICU 평가 시점 이전 8시간 데이터 기반
- 분석 단위:** 개별 CAM-ICU 평가 시점 (환자당 다수 평가 포함)

1.3 전체 파이프라인

1_mimiciv_extraction.sql

2_Data_transform.ipynb

3_Models.ipynb



2. 데이터 추출

2.1 데이터 소스

MIMIC-IV 데이터베이스의 다음 테이블을 사용하였습니다:

테이블	설명	사용 목적
CHARTEVENTS	활력징후, 섬망평가, 의식수준 등	CAM-ICU, RASS, 활력징후
LABEVENTS	검사실 결과	혈액, 전해질, 간/신장 수치
INPUTEVENTS	약물 투여 기록	진정제, 승압제
PATIENTS	환자 기본 정보	연령, 성별
ICUSTAYS	ICU 체류 정보	입퇴실 시간, 재원기간

2.2 코호트 정의

포함 기준: - CAM-ICU 평가 기록이 있는 ICU stay - 18세 이상 성인 - ICU 재원기간(LOS) 8일 이상

원본 데이터 규모:

단계	데이터	규모
원본	all_events	38,276,100개 이벤트
원본	adm_pat_icu	72,729개 ICU stay

2.3 추출 변수

활력징후 (CHARTEVENTS)

- Heart Rate, Temperature, Mean BP, Oxygen Saturation
- Richmond-RAS Scale (RASS)
- CAM-ICU 하위 항목 (Inattention, MS Change, RASS LOC, Disorganized thinking)

검사실 결과 (LABEVENTS)

- 혈액: WBC, Hemoglobin, Hematocrit, Platelets
- 전해질: Sodium, Potassium, Chloride, Bicarbonate, Calcium, Magnesium, Phosphate
- 신장/간: BUN, Creatinine, ALT
- 기타: Glucose, Lactate, pH, pCO₂, pO₂

약물 투여 (INPUTEVENTS)

- 진정제: Propofol, Benzodiazepines (Midazolam, Lorazepam, Diazepam), Ketamine
- 진통제: Opiates (Fentanyl, Morphine)
- 승압제: Vasopressors (Vasopressin, Dobutamine, Phenylephrine)

3. 데이터 전처리

3.1 단위 변환

일관성 있는 분석을 위해 다음 단위 변환을 수행하였습니다:

변환	공식	해당 행 수
Temperature °F → °C	$(F - 32) \times 5/9$	738,677
Weight lbs → kg	$lbs \times 0.453592$	19,365
Height inch → cm	$inch \times 2.54$	101

3.2 라벨 통합

동일한 의미를 가진 여러 변수를 단일 라벨로 통합하였습니다:

통합 라벨	원본 라벨
RASS	Richmond-RAS Scale, Goal Richmond-RAS Scale
Weight	Admission Weight (Kg), Admission Weight (lbs.), Daily Weight
Temperature	Temperature Fahrenheit, Temperature Celsius

통합 라벨	원본 라벨
Opiates	Fentanyl, Fentanyl (Concentrate), Morphine Sulfate
Benzodiazepines	Midazolam (Versed), Lorazepam (Ativan), Diazepam (Valium)

3.3 시계열 변환

- ICU 입실(intime) 기준 시간(hours) 계산
- 60분 단위 비닝 (bin = floor(hours))
- Wide format 피봇 테이블 생성

시계열 데이터 규모:

단계	행 수	ICU stay 수
LOS ≥ 8일 필터링 후	17,400,216	7,661
시계열 피봇 후	2,868,290	7,661

3.4 CAM-ICU 분류

CAM-ICU 양성 판정 기준:

CAM-ICU Positive = (Feature1 AND Feature2) AND (Feature3 OR Feature4)

Feature1: CAM-ICU MS Change == 1 (의식 변화)

Feature2: CAM-ICU Inattention == 1 or 4 (주의력 장애)

Feature3: CAM-ICU RASS LOC == 1 (의식 수준 변화)

Feature4: CAM-ICU Disorganized thinking == 1 (비조직적 사고)

CAM-ICU 평가 현황:

구분	개수
전체 시계열 레코드	2,868,290
CAM-ICU 평가 시점	200,909
- 양성 (Positive)	6,767 (3.37%)
- 음성 (Negative)	194,142 (96.63%)
미평가 시점 (NaN)	2,667,381

환자 수준 분포: - 섬망 경험 환자 (ever delirious): 2,471명 - 섬망 비경험 환자 (never delirious): 5,185명

3.5 결측치 처리 (Imputation)

단계	대상 변수	처리 방법
1	약물/장비	NaN → 0 (미기록 = 미사용)
2	Weight, Height	환자별 forward-fill + backward-fill
3	임상 측정값	환자별 forward-fill
4	임상 측정값	환자별 backward-fill (초기 시간대)

3.6 8시간 윈도우 집계

CAM-ICU 평가 시점(cam_bin)으로부터 이전 8시간(cam_bin-7 ~ cam_bin) 데이터를 하나의 행으로 집계하였습니다.

필터링: `cam_bin >= 7` (입실 후 8시간 미만 평가 제외)

집계 규칙:

구분	변수	집계 방법
활력징후	Heart Rate, Mean BP, Oxygen Saturation, Temperature	8h mean + std
약물/장비	Propofol, Opiates, Benzodiazepines 등	8h 내 사용 여부 → 1/0
검사/의식	Weight, RASS, Lab 결과	최신 시점 값

제외된 변수 (결측률 높음):

변수	결측률	제외 사유
Height	98.6%	대부분 미측정
Ammonia	91.2%	대부분 미측정
Albumin	19.0%	높은 결측률
Bilirubin	12.4%	높은 결측률
AST	11.3%	높은 결측률

4. 탐색적 데이터 분석

4.1 최종 데이터셋 규모

항목	값
총 샘플 수 (CAM-ICU 평가)	195,440
고유 ICU stay 수	7,644
특성(Feature) 수	37

4.2 타겟 변수 분포

샘플 수준 (Sample-level)

클래스	개수	비율
CAM-ICU 음성 (0)	188,739	96.57%
CAM-ICU 양성 (1)	6,701	3.43%

환자 수준 (Patient-level)

클래스	환자 수	비율
섬망 비경험 (Never)	5,207	68.12%
섬망 경험 (Ever)	2,437	31.88%

4.3 클래스 불균형 처리

심각한 클래스 불균형(양성률 3.43%)에 대응하기 위해: - sklearn: `class_weight='balanced'` 적용 - XGBoost: `scale_pos_weight = neg_count / pos_count` 적용 - PyTorch MLP: `BCEWithLogitsLoss + pos_weight` 적용

계산된 클래스 가중치: - Class 0 (음성): 0.5178 - Class 1 (양성): 14.5829 - 가중치 비율: **28.2x**

4.4 최종 변수 목록 (37개)

구분	변수명	개수
인구통계	age, gender	2
활력징후 (mean)	Heart Rate, Mean BP, Oxygen Saturation, Temperature	4
활력징후 (std)	Heart Rate_std, Mean BP_std, Oxygen Saturation_std, Temperature_std	4
약물	Propofol, Opiates, Benzodiazepines, Ketamine, Vasopressors	5
장비	Ventilator	1

구분	변수명	개수
의식	RASS	1
신체계측	Weight	1
혈액	WBC, Hemoglobin, Hematocrit, Platelets	4
전해질	Sodium, Potassium, Chloride, Bicarbonate, Calcium, Magnesium, Phosphate	7
신장/간	BUN, Creatinine, ALT	3
기타 검사	Glucose, Lactate, pH, pCO2, pO2	5

5. 모델링

5.1 데이터 분할

세트	샘플 수	양성 수	양성률
Train	156,352	5,361	3.43%
Test	39,088	1,340	3.43%

- Stratified split (층화 추출)으로 클래스 비율 유지
- test_size = 0.2
- random_state = 42

5.2 전처리 파이프라인

1. 이상치 처리: IQR 기반 clipping (연속형 변수)
2. 결측치 처리: Train set 기준 median imputation

5.3 모델 구성

모델	라이브러리	특이사항
Logistic Regression (LR)	sklearn	solver=liblinear, class_weight=balanced, StandardScaler
Random Forest (RF)	sklearn	max_features=8, class_weight=balanced
XGBoost (XGB)	xgboost	n_estimators=300, scale_pos_weight
MLP	PyTorch	3-layer, BCEWithLogitsLoss + pos_weight

5.4 Optuna 하이퍼파라미터 튜닝

설정: - 최적화 목표: AUPRC 최대화 - Trial 수: 8 - Cross-validation: 5-Fold

탐색 범위 및 최적 파라미터:

모델	파라미터	탐색 범위	최적값
LR	C	0.01 ~ 100 (log)	63.54
	penalty	l1, l2	l1
RF	n_estimators	100 ~ 500	447
	max_depth	10 ~ 30	25
	min_samples_split	2, 5, 10	2
XGB	learning_rate	0.01 ~ 0.2 (log)	0.079
	max_depth	3 ~ 9	8
	subsample	0.6 ~ 1.0	0.773
MLP	hidden_dim	128, 256, 512	128
	dropout	0.1 ~ 0.5	0.443
	lr	1e-4 ~ 1e-2 (log)	0.00258

Optuna 튜닝 결과 (AUPRC):

모델	Best AUPRC
XGB	0.5072
RF	0.4334
MLP	0.1703
LR	0.1064

5.5 교차 검증

설정: - 5-Fold Stratified K-Fold - Best params 사용

Fold별 샘플 분포:

Fold	Train 샘플	양성 수	Val 샘플	양성 수
1	125,081	4,289	31,271	1,072
2	125,081	4,288	31,271	1,073

Fold	Train 샘플	양성 수	Val 샘플	양성 수
3	125,082	4,289	31,270	1,072
4	125,082	4,289	31,270	1,072
5	125,082	4,289	31,270	1,072

6. 결과

6.1 교차 검증 결과 (5-Fold, Best Params)

모델	AUC-ROC (95% CI)	AUPRC (95% CI)	PPV	NPV	MCC
XGB	0.9602 (0.9582-0.9622)	0.5072 (0.4888-0.5256)	0.4058	0.9906	0.5283
RF	0.9548 (0.9507-0.9588)	0.4334 (0.4042-0.4626)	0.3597	0.9921	0.5093
MLP	0.8631 (0.8607-0.8655)	0.1769 (0.1670-0.1868)	0.0987	0.9936	0.2330
LR	0.8052 (0.8017-0.8088)	0.1064 (0.1026-0.1103)	0.0752	0.9918	0.1794

6.2 Test Set 최종 결과 (Optuna Best Params)

모델	AUC-ROC	AUPRC	PPV	NPV	MCC	Spec@90
XGB	0.9593	0.5045	0.3960	0.9913	0.5285	0.9317
RF	0.9538	0.4294	0.3571	0.9922	0.5086	0.9305
MLP	0.8632	0.1801	0.1015	0.9929	0.2349	0.6832
LR	0.8072	0.1102	0.0748	0.9915	0.1774	0.5378

Spec@90: 90% Sensitivity에서의 Specificity

6.3 Quick CV 결과 (Default Params, 비교용)

모델	AUC-ROC (95% CI)	AUPRC (95% CI)
XGB	0.9592 (0.9569-0.9615)	0.4794 (0.4590-0.4998)
RF	0.9531 (0.9493-0.9569)	0.4180 (0.3866-0.4494)

모델	AUC-ROC (95% CI)	AUPRC (95% CI)
LR	0.8049 (0.8013-0.8085)	0.1063 (0.1025-0.1101)

→ Optuna 튜닝으로 XGB AUPRC **5.2%p 향상** (0.4794 → 0.5045)

6.4 성능 해석

Baseline 대비 성능

- 단순 양성률 기반 baseline AUPRC: **0.0343** (3.43%)
- XGB AUPRC: **0.5045** → baseline 대비 **14.7배** 향상

클래스 불균형 하에서의 해석

- 높은 NPV (>99%)**: 음성 예측의 높은 신뢰도 (실제 음성을 잘 맞춤)
- 중간 PPV (~40%)**: 양성 예측 시 약 40%가 실제 양성
- 높은 Spec@90 (93%)**: 90% sensitivity 유지하면서 93% specificity 달성

7. 결론 및 논의

7.1 주요 발견

- XGBoost가 최고 성능 달성**
- AUC-ROC 0.96, AUPRC 0.50으로 심장 예측에 효과적
- 3.43%의 극심한 클래스 불균형에서도 우수한 성능
- Tree 기반 모델의 우수성**
- RF, XGB가 LR, MLP보다 현저히 높은 성능
- 비선형 관계 및 변수 간 상호작용 포착에 유리
- 딥러닝(MLP)의 제한적 성능**
- 표 형식 데이터에서 MLP는 tree 기반 모델 대비 열위
- 충분한 데이터에도 불구하고 AUPRC 0.18로 제한적

7.2 임상적 의의

- 스크리닝 도구로서의 활용**: 높은 NPV로 음성 예측 신뢰 가능
- 고위험군 식별**: PPV 40%로 양성 예측 환자 집중 관리 가능
- 8시간 윈도우 기반 예측**: 실시간 모니터링 시스템 적용 가능

7.3 한계점

1. 단일 기관 데이터: MIMIC-IV (Beth Israel Deaconess Medical Center)로 일반화 제한
2. 후향적 연구: 전향적 검증 필요
3. CAM-ICU 의존: 평가 누락 시점 예측 불가
4. 시간 의존성 미고려: 순차적 패턴 미반영 (LSTM 등 미적용)

7.4 향후 연구 방향

- 외부 검증 (eICU, 국내 데이터)
- 시계열 모델 적용 (LSTM, Transformer)
- 설명 가능성 분석 (SHAP, Feature Importance)
- 전향적 임상 검증

부록

A. 파일 구조

```
YonseiAIChallenge/
├── src/
│   ├── 1_mimiciv_extraction.sql    # 데이터 추출 SQL
│   ├── 2_Data_transform.ipynb      # 데이터 전처리
│   └── 3_Models.ipynb              # 모델링
├── Data/
│   ├── all_events.csv              # 원본 이벤트 (38.3M rows)
│   ├── adm_pat_icu.csv             # ICU 체류 정보 (72.7K stays)
│   ├── all_timeseries.csv           # 시계열 (2.9M rows)
│   ├── timeseries_imputed.csv       # Imputation 완료
│   └── final_dataset.csv            # 최종 (195.4K rows)
├── models/
│   ├── optuna/                     # Optuna 튜닝 모델
│   └── quick/                       # Default 모델
└── docs/
    ├── 1-Data_extraction_MIMIC_workflow.md
    ├── 2-Data_transform_workflow.md
    └── 3-Models_workflow.md
```

B. 주요 설정값

```
SEED_VALUE = 42
N_SPLITS = 5          # K-Fold CV
N_TRIALS = 8          # Optuna trials
N_JOBS = 4            # Parallel jobs
```

```
TEST_SIZE = 0.2          # Train/Test split
DATA_DIR = '../Data'
OPTUNA_SAVE_DIR = '../models/optuna'
```

C. 데이터 흐름 요약

단계	파일	행 수	ICU stay 수
원본 추출	all_events.csv	38,276,100	72,729
LOS 필터링	-	17,400,216	7,661
시계열 피봇	all_timeseries.csv	2,868,290	7,661
Imputation	timeseries_imputed.csv	2,868,290	7,661
8h 윈도우 집계	final_dataset.csv	195,440	7,644